

実用的な大規模並列モンテカルロ木探索の分子設計への応用

Practical Massively Parallel Monte-Carlo Tree Search Applied to Molecular Design

Xiufeng Yang (中外製薬株式会社)、Tanuj Kr Aasawat (Intel Labs - インド)、Kazuki Yoshizoe (理化学研究所 革新知能統合研究センター)

※ 本研究は著者全員が理化学研究所在籍中に実施

概要

大規模な計算資源を用いてニューラルネットワークを訓練することは、強化学習などの分野で広く行われている一般的な手法です。しかし、大規模並列コンピューティングはモデルの訓練に活用されることが多い一方で、組合せ最適化問題の解探索にはほとんど用いられていません。本論文では、複数の計算ノードを使う分散メモリ環境において1,000ワーカー規模で効率的に動作する新しい大規模並列モンテカルロ木探索 (MP-MCTS) アルゴリズムを提案し、分子設計問題に応用します。本研究は分散MCTSを実世界のゲーム以外の問題に初めて適用した研究です。

大規模並列MCTSに関する既存研究は、最大100ワーカー規模のロールアウト数において効率的なスケーラビリティを示していますが、解の品質の低下という問題を抱えています。MP-MCTSはより大規模なスケールでも探索品質を維持します。256個のCPUコアでMP-MCTSをわずか10分間実行することで、非並列MCTSを42時間実行した場合と同等のスコアを持つ候補分子を取得できました。さらに、並列MCTS (シンプルなRNNモデルと組み合わせ) に基づく本手法の結果は、既存の最先端研究を大幅に上回っています。本手法は汎用的であり、MCTSの他の応用分野でも高速化が期待されます。(コードは <https://github.com/yoshizoe/mp-chemts> で公開)

1. はじめに

MCTSに関する2012年のサーベイ論文は、ゲームおよび非ゲームへの多くの応用を含む240本の論文を引用しています。最も代表的なMCTSアルゴリズムであるUCT (Upper Confidence bound applied to Trees) が2006年に考案されて以来、MCTSは様々な問題で顕著な性能を示してきました。最近では、コンピュータ囲碁においてAlphaGoが深層ニューラルネットワーク (DNN) との組み合わせに成功し、MCTSが脚光を浴びています。

MCTSとDNNの組み合わせは、意思決定や組合せ最適化問題を解くための標準的なツールの一つになりつつあり、並列MCTSへの需要は非常に高まっています。しかし、近年の多くの研究でDNNモデルの訓練に膨大な並列計算資源が投入されているのとは対照的に、MCTSが大規模に並列化されることはほとんどありません。

MCTSの並列化はUCTの性質から難しく、非並列の通常UCTでは選択・展開・ロールアウト・逆伝播の4ステップを経てロールアウトのたびに木のノードの値を更新します。次の選択ステップの動作は以前のロールアウトと逆伝播の結果に依存するため、アルゴリズムに明示的な並列性がありません。

仮想損失 (virtual loss) 技術により、CPUコア数が限られた共有メモリの単一マシン環境でMCTSを効率的に並列化する研究が行われてきましたが、分散メモリ環境を用いた大規模並列MCTSの研究は限られています。効率的にスケールする手法は2つしかなく、いずれもロールアウト数という観点からのみ検証されており、実際の改善は検証されていません。

最近では、非並列MCTSとDNNを組み合わせた手法が分子設計問題（所望の特性を持つ新しい化合物を見つけることを目的とする）に適用されていますが、大規模並列MCTSを用いた研究は存在しませんでした。本論文では新しい分散並列MCTSを提案し、分子設計問題に適用します。シンプルなRNNモデルと組み合わせた大規模並列MCTSは、ベイズ最適化や強化学習と組み合わせたより複雑なモデルを使用した既存研究を上回ります。

2. 背景

2.1 （非並列）MCTS

2006年にKocsisとSzepesvariはUCB1というマルチアームドバンディットアルゴリズムに基づくUCTを提案しました。UCTは最適解への収束が証明された最初のMCTSアルゴリズムであり、囲碁などの多くの問題で優れた性能を示しています。

UCTの1ラウンドは次の4つのステップから構成されます：

選択（Selection）：アルゴリズムはルートノードから開始し、葉ノードに到達するまでUCB1値が最も高い子を選択します。各子 i に対して、 v_i は訪問回数、 w_i は累積報酬、 V は親ノードの訪問回数です。探索定数 C によって、小さいほど選択的、大きいほど探索的な挙動になります。

展開（Expansion）：訪問回数が所定の閾値を超えた場合、葉ノードを展開して（葉の子を木に追加）、シミュレーションのために新しい子の1つを選択します。それ以外の場合は何もしません。

シミュレーション（Simulation）：UCTはシミュレーションによってノードを評価します。このステップはプレイアウトまたはロールアウトとも呼ばれます。AlphaGoの成功以来、ロールアウトをDNNベースの評価に置き換えることが主流になっています。

逆伝播（Backpropagation）：UCTはパスをルートまでたどり、パス上のノードの値を更新します（ $w_i = w_i + r$ 、 $v_i = v_i + 1$ ）。

2.2 MCTSを用いた分子設計

SMILES (Simplified Molecular-Input Line-Entry System) は化学においてASCII文字列で分子を記述するための標準的な表記法です。SMILESは原子、結合、環構造などの情報をASCII記号で表します。たとえば、二酸化炭素のSMILESは"O=C=O" ("="は二重結合)、ベンゼンは"C1=CC=CC=C1"または"c1ccccc1" ("C1"同士をつないで環を形成)です。

分子設計のための探索空間はSMILESに基づく木として定義できます。ルートノードは開始記号で、深さ d のノードへのパスはSMILES文字列の最初の d 記号を左から右へ列挙したものを表します。

Yang et al. (2017)はAlphaGo的アプローチ（MCTSとDNN、計算化学シミュレーターを組み合わせる）を用いて非並列MCTSをこの問題に初めて適用しました。RNNモデルはZINCデータベースから抽出した25万個の薬剤分子で事前学習され、部分SMILESを入力として次の記号の確率を予測します。このモデルは展開とロールアウトの両方に使用されます。

2.3 並列MCTS

非並列MCTSは選択ステップで最も有望な葉を1つずつ見つけます。並列MCTSでは複数のワーカーが並列に有望な葉を見つける必要があるため、最新の結果を知らずに投機的に葉を見つけないけません。

全てのワーカーがUCB1式に従うと、同じ葉ノードに集中してしまい並列化が失敗します。これを解決するのが仮想損失 (Virtual loss) 技術です。UCB1を修正したUCBv1では、子ノード i の部分木を現在探索中のワーカー数 t_i とその合計 T を考慮します。仮想損失は現在進行中のシミュレーションが0の報酬を得ると仮定するため、後続のワーカーは既に探索されている部分木を避けるようになります。

共有メモリ環境での並列UCT（最大16コア）はGoプログラムの強さを向上させることが証明されていますが、現実の分散マシンでは32コアを超えると有意な高速化は得られませんでした。

2.4 ハッシュ駆動並列探索と均一負荷分散

多くのワーカーが並列に探索を行う場合、探索空間をできるだけ均等に分散することが重要です。ハッシュ駆動（HD）並列探索はこの問題を解決する手法の一つで、IDA*探索の並列化に独立して開発されました。

HD並列探索はハッシュ関数を必要とし、探索中にノードを作成するたびに、ハッシュ関数に基づいてそのノードを特定のワーカー（ホームワーカー）に割り当てます。ハッシュ関数が十分にランダムであれば（Zobristハッシュなど）、ほぼ均等な負荷分散を実現します。ただし、この手法の明確な欠点は、アルゴリズムが分岐をたどるほぼ毎回はワーカー間の通信が必要なことです。

3. 分散並列MCTSと分子設計

3.1 TDS-UCT : ハッシュ駆動並列MCTS

TDS-UCTはUCTへのハッシュ駆動並列探索の適用です。ルートノードを保持するワーカーがUCBv1式に基づいて最良の子を選択し、選択メッセージをその子のホームワーカーに送信します。メッセージを受け取ったワーカーはノードの最良の子を選択し、葉ノードに達するまでメッセージを別のワーカーに渡します。

アイドルワーカーの数を減らすため、選択メッセージ、逆伝播メッセージ、進行中のシミュレーションの合計数はワーカー数を上回る必要があります。実験結果に基づき、オーバーロードファクター $N=3$ を使用します。

3.2 TDS-df-UCT : TDS-UCTの深さ優先再定式化

TDS-UCTのスケラビリティはルートノード付近の通信集中により制限されています。全ての逆伝播メッセージがルートノードまで送られるため、浅いノード（特にルートノード）を保持するワーカーが通信に多くの時間を費やし、100ワーカーを超えるとスケラビリティが急速に低下します。

TDS-df-UCTでは、各ジョブメッセージが現在のパスのノードの兄弟の履歴を含む履歴テーブルを持ちます。シミュレーション後、TDS-df-UCTはノードと履歴テーブルの値を更新し、現在最も有望な部分の木にまだいるかどうかを確認するためにUCBv1を再計算します。ルートノードへのメッセージ数を劇的に削減することで通信集中問題を解決します。

3.3 MP-MCTS : TDS-df-UCTの課題への対処

TDS-df-UCTは履歴をメッセージ内にのみ保持するため、新しい結果を他のジョブに伝播するのに時間がかかります。その結果、他のワーカーがより有望な部分の木を見つけた可能性を見落とすため、逆伝播をスキップしすぎてしまい、木がより広く浅くなってしまいます。

提案するMP-MCTSでは、各ノードが自身の統計情報（ w 、 v 、 t ）とともに履歴テーブルを保持します。これにより最新情報の伝播が加速します（わずかな追加メモリコストで）。TDS-df-UCTへのこの修正は、並列MCTSの動作を改善してより深い木を生成するために非常に重要です。

実験結果は、 N 並列MP-MCTSで得られる解の品質と木の平均深さが、非並列MCTSを N 倍長く実行した理想的なケースと同等であることを示しています。

4. 実験方法

解の品質を評価し最先端手法と比較するために、ペナルティ付きlogP（合成可能性（SA）スコアと大きな環ペナルティスコアによってペナルティを与えたオクタノール-水分分配係数）を使用します。これは分子設計において広く使わ

れるベンチマーク物理化学的特性です。

モデルとデータセット：

ChemTS (yang2017chemts) の公開リポジトリのGRUベースのモデルと事前学習済み重みを使用します。主に2つの積み重ねられたGRUユニットで構成されています。入力データは64次元のone-hotベクトルでSMILES記号を表します。ZINCデータベースから抽出した25万個の薬剤分子のデータセットで事前学習されています。

MCTS実装：

展開ステップでは累積確率が0.95に達するまで高確率の分岐を追加します。ロールアウトでは終端記号が出力されるまでモデルを繰り返しサンプリングして完全なSMILES文字列を生成します。計算化学ツールRDKitを使ってペナルティ付きlogPスコアを計算します。

実験設定：

アルゴリズムはKeras (TensorFlow) とPython用MPI (mpi4py) を用いて実装されました。特に断りのない限り、最大1024コアのCPUクラスター（各ノードにIntel Xeon Gold 6148 CPU 2基（2.4GHz、20コア）と384GBのメモリ）上で10分間実行しました。

5. 実験結果

5.1 ペナルティ付きlogPスコアの最大化

以下の表に、CPUコア数を変えた場合の各手法のペナルティ付きlogPスコアを示します（10回実行の平均と標準偏差、時間制限10分）。

手法	4コア	16コア	64コア	256コア	1024コア
TDS-UCT	5.83±0.31	6.24±0.59	7.47±0.72	7.39±0.92	6.22±0.27
TDS-df-UCT	7.26±0.49	8.14±0.34	8.59±0.49	8.22±0.41	8.34±0.46
MP-MCTS（提案手法）	6.82±0.76	8.01±0.61	9.03±0.85	11.46±1.52*	11.94±2.03*
非並列MCTS（等コア時間）	6.97±0.49	8.54±0.34	9.23±0.53	11.17±0.88	—

* 最高スコア。MP-MCTSは256コアと1024コアでTDS-UCT・TDS-df-UCTを大幅に上回る。

コア数の増加とともに、より多くのシミュレーションを並列実行でき、スコアの品質が向上します。TDS-UCTはコア数増加とともに通信集中による負荷不均衡が顕著になりスコアが低下します。TDS-df-UCTはより均一な負荷分散を達成しますが、スコアの改善はわずかです。MP-MCTSはコア数の増加とともにスコアが単調に改善します。

5.2 並列解と非並列解の品質比較

非並列MCTSを等コア時間分実行した場合と比較すると、大きな計算資源（256・1024コア）を使用した場合、分散MCTSははるかに短い時間でより高いスコアを達成します。これにより、MCTSは解の品質を犠牲にすることなく分散MCTSによって高速化できることが実証されました。

5.3 ルートノードへのメッセージトラフィックの削減

MP-MCTSとTDS-df-UCTはすべてのワーカーにわたってより良い負荷分散を実現しますが、TDS-UCTではルートなどのホットノードのホームワーカーがメッセージに圧倒され、極めて高い負荷不均衡に悩まされます。

5.4 探索木の深さ

TDS-UCTは負荷不均衡のため他の手法より浅い木を生成します。TDS-df-UCTはTDS-UCTより深い木を生成しますが、理想的なケースよりはるかに浅く留まります（逆伝播が少なすぎると推定）。MP-MCTSは256コアで10分間の実行により

、非並列MCTSを2,560分（約42時間）実行した理想的なケースに近い、著しく深い木を生成します。

5.5 分子設計における関連研究との比較

以下の表に、既存の最先端研究との比較を示します（上位3つのペナルティ付きlogPスコア）：

手法	1位	2位	3位	備考
JT-VAE	5.30	4.93	4.49	報告値
GCPN	7.98	7.85	7.80	報告値
MolecularRNN	10.34	10.19	10.14	報告値
MolDQN	9.01	9.01	8.99	報告値（修正版）
Mol-CycleGAN	9.76	7.29	7.27	報告値
GRUベース（Yang et al.）	6.47	5.65	5.01	8時間×10回
MP-MCTS（GRU使用）【提案】	15.13	14.77	14.48	10分×10回

MP-MCTSはペナルティ付きlogPスコアの最大化において既存研究を大幅に上回ります。特にGRUベースモデルのスコアを大幅に改善しており、この結果は既存研究のモデルを並列MCTSと組み合わせることで性能を向上させられる可能性を示唆しています。

6. 関連研究

6.1 分子設計

分子設計では、深層生成モデルを用いて候補分子を生成し、最適化アルゴリズム（主にベイズ最適化（BO）または強化学習（RL））で有望な候補に絞り込む手法が一般的です。Gomez-Bombarelli et al. が変分オートエンコーダ（VAE）を初めて採用し、Kusner et al. がコンテキスト自由文法と組み合わせた文法VAE（GVAE）に発展させました。いずれもBOによる最適化を使用しています。

グラフベースの分子生成であるJT-VAEとGCPNは分子グラフを直接操作して分子を生成し、それぞれBOとRLで最適化します。これらの研究はMCTSを使用していません。Jin et al. (2020)は多目的制約付き分子設計にMCTSを適用しましたが、MCTSは重要なサブ構造の抽出に使い、その後グラフベースの分子生成を訓練するという異なる用途です。

6.2 並列MCTS

DNNとMCTSを組み合わせた単一マシンを超えた研究の中で、分散AlphaGo（1202個のGPUを使用）のみが大規模並列研究です。ただし、1つのマシンのみが探索木を保持し、他のマシンのGPUはニューラルネットワーク計算のみに使用されるため、スケーラビリティは限定的です。

ハッシュ駆動並列探索は、TDS-df-UCT（人工ゲーム向け）とUCT-tree-split（囲碁向け）によって独立に分散MCTSに初めて適用され、通信集中問題を解決しました。UCT-tree-split は各ワーカーに訪問回数の多いノードを含む複製された部分木を保持させ、定期的に同期しますが、TDS-df-UCTより通信オーバーヘッドが高くなります。

他の分散並列MCTS手法には根並列化と葉並列化があります。根並列化は異なるランダムシードで複数のMCTS実行を行い浅い部分を同期しますが、木のサイズが非並列MCTSと同程度のため改善は限定的です。葉並列化の性能は根並列化より低いです。

7. 結論

分子設計へのMCTSの応用はまだ十分に研究されていません。本研究は分子設計に対する分散並列MCTSを初めて探求した研究です。大規模な実験により、効率的な分散MCTSが、ベイズ最適化や強化学習と組み合わせたより複雑なDNNモ

デルを使用する他の手法を大幅に上回ることが示されました。さらに、実世界問題において非並列MCTSと比べて探索能力を犠牲にしません。

今後の研究として、より複雑で改善されたモデルと並列MCTSを組み合わせることで分子設計の性能をさらに向上させることが考えられます。また、MP-MCTSは逆合成解析（AlphaGo的アプローチが適用されている）など他のMCTS応用にも適用できます。提案した並列化技術は化学特有のコンポーネントから独立しており、ゲームおよび非ゲームの他の応用にも適用できます。本実験の結果は、MCTSが実世界の最適化問題においてより優れた選択肢となりうることを強く示唆しています。

謝辞：本研究はJSPS科研費（20H04251）の一部支援を受けました。実験は理化学研究所AIPのRAIDENコンピュータシステムで実施されました。

※ 本文書は arXiv:2006.10504v3 「Practical Massively Parallel Monte-Carlo Tree Search Applied to Molecular Design」の日本語翻訳です。